

Entrega 1 — Priorizar el despacho de una cuadrilla

Machine Learning

Contexto

Esta entrega trabaja sobre datos abiertos reales del Uruguay.

OSE —Obras Sanitarias del Estado— publica, bajo la Licencia de Datos Abiertos del Uruguay, el registro de las solicitudes y reclamos operativos que recibe: falta de agua, baja presión, pérdidas en la vía pública, desbordes de saneamiento, problemas de calidad del agua y solicitudes de reposición de pavimento y señalización. El archivo de 2024 tiene **390 886 filas**, una por reclamo, y es el conjunto sobre el que se trabaja.

Recurso	Dónde
Conjunto «Solicitudes y reclamos operativos»	datos.ose.com.uy
Portal de datos abiertos de OSE	datos.ose.com.uy
Catálogo Nacional de Datos Abiertos	catalogodatos.gub.uy
Licencia de Datos Abiertos del Uruguay	gub.uy

El registro publicado no incluye todo lo que el caso necesita. **La cátedra aporta un archivo complemento** con tres columnas adicionales para el subconjunto de reclamos del ejercicio, y la primera tarea del trabajo es **construir la tabla final uniendo las dos fuentes**.

La decisión

Cuando un reclamo ingresa, el centro técnico de la zona decide qué hacer con él: encolarlo en el circuito normal de trabajo, o **despachar una cuadrilla prioritaria** que lo saque de la secuencia programada. El organismo compromete un **plazo de 72 horas** para resolver un reclamo operativo. Incumplirlo no es un problema de imagen: dispara un reclamo reiterado, una segunda salida de cuadrilla y exposición ante el regulador.

La organización quiere dos cosas del mismo sistema, y las quiere **en el momento en que el reclamo ingresa**:

1. **Estimar cuánto va a tardar la resolución**, para planificar la carga de trabajo de las cuadrillas de cada centro técnico. Es una respuesta continua: el tiempo de resolución, en horas.
2. **Decidir si prioriza el reclamo**, movilizándolo una cuadrilla antes de que el plazo se incumpla. Es una respuesta binaria: el reclamo supera las 72 horas o no. **Esa columna no viene en ningún archivo: se deriva del plazo comprometido**, y derivarla obliga a decidir antes qué hacer con los registros cuyo tiempo es imposible.

Cómo se registra la información de un reclamo

El organismo acumula tres capas de información sobre cada reclamo, y las tres se archivan juntas contra el mismo registro histórico:

- **Al ingresar el reclamo**, el centro registra la región y el departamento, la fecha y hora, el tipo de reclamo, la complejidad estimada del trabajo, si se denuncia ausencia de agua, baja presión o inundación, la distancia desde el centro técnico hasta el punto reclamado y cuántas conexiones quedan afectadas.
- **Al cerrar el reclamo**, queda asentado cuánto tardó efectivamente la resolución, qué centro técnico lo atendió, bajo qué tipo de orden de trabajo y si el reclamo correspondía o no.
- **Días después del cierre**, quien hizo el reclamo responde una encuesta de satisfacción, cuyo resultado se archiva contra el reclamo.

El modelo, en cambio, **se ejecuta en el momento en que el reclamo ingresa**: produce las dos respuestas cuando el operador termina de tomarlo, no cuando el histórico termina de completarse. Toda información que el sistema use como entrada tiene que existir en ese instante. **Determinar qué parte del registro cumple esa condición y qué parte no la cumple es parte del trabajo**, y ninguna sección posterior es válida si esa determinación no se hizo antes.

El volumen anual del organismo ronda los **390 000 reclamos operativos**, cifra que permite expresar el resultado de la decisión en dinero y no en proporciones.

Los datos

Paso 1 — descargar el archivo de OSE

Desde datos.ose.com.uy, el recurso «**Solicitudes y reclamos operativos 2024**»: un ZIP de unos 10 MB que descomprime a un CSV de unos 114 MB, **separado por punto y coma**.

Paso 2 — el complemento de la cátedra

`data/entregas_reclamos_complemento.csv`

Trae el identificador de reclamo y tres columnas que OSE no publica y que el caso necesita. Los identificadores del complemento son un subconjunto de los del archivo de OSE.

Paso 3 — construir la tabla de trabajo

Filtrar el archivo de OSE a los reclamos que aparecen en el complemento y **unir las dos fuentes por el identificador**. El resultado de esa unión es el conjunto sobre el que se trabaja de la sección 2 en adelante, y **la sección 1 tiene que dejar constancia de que la unión no perdió ni duplicó filas**.

Sobre la naturaleza de los datos. La estructura del caso, las dos respuestas y la mayor parte de lo que el archivo contiene provienen del registro real de OSE. Las tres columnas del complemento fueron construidas por la cátedra con fines didácticos. **Ninguna conclusión de este trabajo constituye un diagnóstico sobre la gestión del organismo**, y así debe declararse en la sección de conclusiones.

No se entrega diccionario de variables ni descripción de la calidad del archivo. OSE publica en su portal un recurso de metadatos que describe qué mide cada columna del registro original, y consultarlo es parte del trabajo profesional. Lo que ningún metadato dice es **en qué estado llega el archivo ni qué información existe en el momento en que el reclamo ingresa**: caracterizar el conjunto —unidades, defectos, faltantes y disponibilidad temporal— es la primera consigna, y nada de eso se da por conocido en este documento.

Qué hay que entregar

Un notebook construido sobre el template obligatorio `entrega_reclamos_ose_template.ipynb`, que fija las trece secciones y su orden. Cada sección tiene una consigna propia, y las secciones posteriores se apoyan en las decisiones de las anteriores.

1. Ingesta, unión y auditoría del conjunto

Documentar la construcción de la tabla de trabajo: cuántas filas trae cada fuente, cuántas sobreviven al filtro, cuántas quedan después de la unión y **qué garantiza que la unión no perdió ni multiplicó registros**. Una unión que cambia el número de filas sin explicación es un error de la sección, no un detalle.

Caracterizar después el archivo, antes de ajustar ningún modelo: dimensiones, tipos, resumen descriptivo, distribución de cada variable, valores faltantes por columna y el patrón que siguen, filas repetidas, valores imposibles y cardinalidad de las variables categóricas.

Para **cada** variable con faltantes, diagnosticar el mecanismo —MCAR, MAR o MNAR— y sostener el diagnóstico con el contraste que lo separa de las otras dos alternativas. Cuando el mecanismo no sea diagnosticable con los datos observados, decirlo y explicar por qué. **El tratamiento se deriva del diagnóstico, no al revés.**

Construir por último la respuesta binaria a partir del plazo comprometido, dejando dicho qué se hizo con los registros para los que esa construcción no tiene sentido.

La sección cierra con un **informe de hallazgos**: una tabla de tres columnas —defecto, evidencia que lo produce, decisión propuesta—. Un hallazgo sin la cifra o el gráfico que lo produce no cuenta como hallazgo.

2. Preparación dentro de un pipeline

Ejecutar las decisiones de la sección 1 dentro de un Pipeline con `ColumnTransformer`. **Ninguna transformación que aprenda algo de los datos** —una media, una mediana, una escala, una lista de categorías— **puede ubicarse fuera del pipeline**. La limpieza determinista, que no estima nada a partir de la muestra, puede hacerse antes y no se penaliza.

Declarar explícitamente **qué columnas quedan fuera de la matriz de entrada y por qué**. Cada exclusión se justifica una por una, y la justificación de disponibilidad en el momento en que el reclamo ingresa es distinta de la justificación por desempeño: si una columna se excluye por las dos razones, corresponde decir cuál manda.

3. Línea base

Antes de ajustar el primer modelo. Para la regresión, predecir siempre la media de la respuesta; para la clasificación, la prevalencia observada. Reportar las métricas de las dos líneas base y **declarar que todo número posterior se informa contra ellas**.

En regresión, al menos una de las métricas reportadas tiene que estar en las unidades de la respuesta, porque es la única forma de que la comparación se lea como una mejora operativa y no como un número abstracto.

Una línea base que se calcula y no se vuelve a citar no cuenta: **las secciones 4 a 13 la usan**.

4. Regresión sobre el tiempo de resolución

Ajustar una regresión lineal por mínimos cuadrados sobre la preparación de la sección 2.

La forma de la distribución de la respuesta, medida en la sección 1, condiciona si conviene modelarla directamente o transformada. **La decisión es del grupo y se deriva de esa medición**, no de la costumbre; si se transforma, el resultado tiene que poder volver a leerse en horas.

Leer los coeficientes en las unidades del caso: cuánto agrega un kilómetro más de distancia, cuánto una conexión afectada más. Los coeficientes se interpretan, no se listan.

Reportar el resultado contra la línea base de la sección 3, y expresar la mejora también en la unidad que la organización entiende, que son horas y no proporciones de varianza.

5. Regularización: Ridge y Lasso

Ajustar Ridge y Lasso sobre exactamente la misma preparación y comparar los tres modelos —mínimos cuadrados, Ridge y Lasso— sobre la misma validación.

- El coeficiente de regularización λ **se elige por validación cruzada**, nunca a mano.
- **La grilla de λ se declara** en el notebook y es logarítmica. Si el λ elegido cae en un extremo de la grilla, eso significa que el óptimo está afuera: corresponde decirlo y ampliarla.
- **Interpretar qué variables anula Lasso.** La lista de coeficientes en cero es el resultado de esta sección, no una salida de pantalla que se imprime y se deja.

Concluir si la penalización aporta algo **en este problema**, y sostener la conclusión con la razón que la explica y no solo con la diferencia de métrica. Una conclusión negativa bien argumentada es una respuesta correcta.

6. Clasificación del incumplimiento del plazo

Ajustar una regresión logística sobre la misma preparación. Reportar la matriz de confusión y el conjunto de métricas que corresponda a la **distribución de la respuesta medida en la sección 1**, argumentando cuál de ellas manda en este problema y por qué. Todo se informa contra la línea base de la sección 3.

7. Evaluación con validación cruzada

Estimar el desempeño de todos los modelos ajustados hasta acá con validación cruzada de k folds, estratificada en el problema de clasificación. **Reportar media y desvío: ningún número se informa solo.**

La validación cruzada **envuelve al pipeline completo**, no al revés. Y hay decisiones de la sección 1 que tienen que estar tomadas **antes** de particionar, porque de lo contrario la partición queda contaminada: identificar cuáles son y explicar por qué el orden importa.

8. El costo del leakage: los dos flujos

Usar como entrada una columna que no existe en el momento de decidir se llama *data leakage* —fuga de información—, y de acá en más, **leakage**. Esta sección lo mide.

Sobre el problema de clasificación, construir **dos flujos completos**:

- el **honesto**, que excluye las columnas que la sección 2 dejó fuera por no estar disponibles en el momento en que el reclamo ingresa;
- el **contaminado**, que las conserva.

Evaluar los dos con **exactamente la misma** validación cruzada y **reportar la brecha entre ellos como número**.

Los dos flujos difieren **solo en las columnas de entrada**. Si entre uno y otro también cambia el modelo, el preprocesamiento o los folds, la brecha dejó de medir el leakage y pasó a medir una suma que no se puede descomponer.

Interpretar la brecha: ese es el desempeño que el modelo **aparentaría** en validación y no tendría en producción. **Declarar el leakage sin medirlo no cumple la consigna**, y es exactamente lo que esta sección existe para impedir.

9. Elección del umbral por costos

Con las cifras de *Los costos del problema*, **derivar** el umbral de probabilidad que minimiza el costo esperado por reclamo. Aplicarlo al clasificador de la sección 6 y comparar el costo resultante contra tres alternativas: el umbral 0,5, priorizar todos los reclamos y no priorizar ninguno.

Las cuatro políticas se comparan **en dinero**, por reclamo y sobre el volumen anual. Se corrige la derivación y la lectura, no la coincidencia con una cifra esperada.

Coherencia con la sección 6: si se remuestreó o se ponderaron las clases, las probabilidades predichas quedan descalibradas y el umbral deducido no se aplica sobre ellas sin corregirlas antes.

10. Tres familias bajo el mismo defecto

Esta sección se apoya en árboles de decisión, que se dictan más adelante en el curso. El plazo de entrega lo contempla con holgura, pero conviene planificar el trabajo del grupo sabiéndolo. k vecinos más cercanos ya está dictado.

Ajustar **k vecinos más cercanos** y un **árbol de decisión**, cada uno con su hiperparámetro elegido por validación cruzada, **dos veces**: sobre los datos bien preparados y sobre los mismos datos **sin escalar**. Someter al modelo lineal de la sección 4 **al mismo cambio**.

Repetir además el ejercicio **cambiando la unidad de una de las variables continuas**, y reportar las combinaciones resultantes en **una sola tabla** con las tres familias.

Concluir qué le hace la preparación a cada una de las tres. **Las tres no se comportan igual, y explicar por qué es el objetivo de la sección.**

- **No es una sección de modelado.** No importa cuál de las tres familias gana, y los únicos hiperparámetros que se ajustan son el k de k vecinos y la profundidad del árbol.
- **Las grillas se declaran y tienen que llegar lo bastante alto.** Si el valor elegido queda pegado a un borde, el barrido se cortó antes del óptimo.
- Entre una rama y otra **puede cambiar una sola cosa**. Si también cambia la imputación, la codificación o el hiperparámetro fijado a mano, el contraste no mide lo que dice medir.

Lo que se evalúa es la conclusión, no el desempeño alcanzado.

11. Reglas de decisión

Ajustar un árbol de clasificación **deliberadamente pequeño** —una profundidad que un supervisor de guardia pueda leer— y **extraer sus reglas en lenguaje del caso**: la ruta de la raíz a cada hoja, traducida a una condición operativa sobre reclamos.

Para cada hoja, reportar **cuántos reclamos caen en ella y qué proporción de ellos incumple el plazo**, y contrastar esa proporción con la prevalencia general. Una hoja que no se aparta de la prevalencia no es una regla: es la media disfrazada.

Comparar el desempeño de ese árbol pequeño contra el clasificador de la sección 6 y discutir **qué se pierde y qué se gana** al reemplazar un modelo por un puñado de reglas. La discusión tiene

que hablar de la operación —quién aplica la regla, con qué información y en cuánto tiempo—, no solo de métricas.

Este es el único punto de la entrega donde se pide interpretabilidad, y se pide como reglas explícitas, no como importancias de variables.

12. Autocrítica del flujo

Sin código: es texto, y se escribe al final, sobre el flujo propio, releendo lo que el grupo efectivamente hizo en las secciones anteriores.

Identificar **la decisión metodológica más frágil del propio trabajo** —una sola, elegida y argumentada—, explicar **qué la haría fallar** y qué evidencia adicional la confirmaría o la descartaría.

No se acepta una fragilidad genérica del aprendizaje automático ni una limitación abstracta del conjunto de datos. La respuesta tiene que **nombrar una decisión que el grupo tomó**, en una sección concreta, y decir **qué número del notebook cambiaría** si esa decisión estuviera mal. Tampoco cuenta una fragilidad que el propio notebook ya resolvió.

Se evalúa con la rúbrica de los parciales: identificar la falencia (2), explicar cómo afecta al modelo (2), proponer la corrección (1).

13. Conclusiones y límites

Qué se recomienda a la organización, con qué desempeño y a qué costo, **contra la línea base de la sección 3 y expresado en dinero**.

Y qué no se puede concluir con estos datos. Los límites tienen que ser los de este caso —los que la auditoría de la sección 1 y la evaluación de la sección 7 dejaron a la vista—, no una lista genérica de advertencias sobre el aprendizaje automático. Entre ellos, el que impone trabajar sobre un registro parcialmente construido con fines didácticos.

Qué hace suficiente a una justificación

Buena parte de las decisiones de esta entrega son abiertas: qué variables conservar, cómo tratar los faltantes, qué modelo recomendar. **Se evalúa la justificación, no la coincidencia con una respuesta esperada**. Una justificación es suficiente cuando cumple las tres condiciones:

1. **Nombra la alternativa que se descartó**. «Se imputó por la mediana» no es una justificación; «se imputó por la mediana y no por la media porque...» sí lo es.
2. **Dice qué propiedad de los datos o del problema descarta esa alternativa**. La propiedad medida, no la costumbre: «es buena práctica» no es una propiedad.
3. **Cuando la decisión es medible, muestra la medición**. Si el grupo afirma que una corrección mejora el ajuste, la comparación tiene que estar en el notebook.

Una justificación que solo describe lo que se hizo **no es una justificación**. Y en las secciones 5, 8 y 10, que comparan flujos, la comparación solo vale si difieren en **una sola cosa**.

Los costos del problema

Priorizar un reclamo no es gratis, y no priorizarlo tampoco. Los dos errores cuestan, y cuestan distinto:

Error	Qué pasa en la operación	Costo
Priorizar un reclamo que no iba a superar el plazo	Se moviliza una cuadrilla fuera de la secuencia programada y se posterga trabajo ya planificado	USD 45
No priorizar uno que sí lo supera	Reclamo reiterado, segunda salida de cuadrilla, gestión del incumplimiento y exposición ante el regulador	USD 270

Sobre esas dos cifras se apoya la sección 9. **La razón entre los dos costos es lo que fija el umbral**, y esa relación tiene que quedar derivada en el notebook, no adoptada de un valor por defecto. El volumen anual de referencia para expresar el resultado en dinero es de 390 000 reclamos.

Alcance

Lo que sigue **no se pide** y no se evalúa. Está acotado para que el esfuerzo del grupo se concentre en las trece secciones:

- **Ninguna familia de modelos fuera de las pedidas.** Los modelos de la entrega son la regresión lineal, sus versiones regularizadas, la regresión logística, k vecinos más cercanos y el árbol de decisión en el rol que les dan las secciones 10 y 11. Máquinas de vectores de soporte, bosques, boosting y redes quedan fuera: usarlas no suma puntaje, y tampoco resta, siempre que las secciones pedidas estén completas.
- **Ajuste de hiperparámetros más allá de dos ejes:** el λ de Ridge y Lasso, el k de k vecinos y la profundidad del árbol. Nada de validación cruzada anidada ni de búsquedas sobre espacios amplios. En particular, **no se pide podar el árbol por costo-complejidad.**
- **Interpretación de importancias de variables**, en cualquiera de sus formas. La sección 11 pide reglas, que son otra cosa.
- **Reducción de dimensión**, calibración de probabilidades, imputación por modelo, transformaciones de potencia, ingeniería de atributos exhaustiva, inferencia estadística sobre los coeficientes, interpretabilidad posterior al ajuste, análisis de equidad entre subgrupos, análisis de supervivencia y puesta en producción.

No hay un desempeño mínimo que alcanzar. No existe un piso de R^2 ni de AUC: una conclusión honesta y bien sostenida de que el modelo aporta poco vale más que una cifra alta sin respaldo.

Condiciones de entrega

Modalidad	Grupos de 4 integrantes
Peso	10 % de la calificación final
Formato	Notebook construido sobre <code>entrega_reclamos_ose_template.ipynb</code> , respetando las trece secciones y su orden
Estado	Ejecutado de punta a punta , con todas las salidas visibles
Vencimiento	Martes 6 de octubre

Un notebook sin ejecutar no está entregado. Las celdas de código tienen que mostrar su salida, y las afirmaciones del texto tienen que corresponderse con esa salida: una conclusión que el notebook no respalda con un número visible se corrige como si no estuviera.

El notebook tiene que poder reproducirse. Como la tabla de trabajo se construye a partir de una descarga externa, el código de ingesta y unión queda en el notebook, y la ruta del archivo descargado se declara en una única celda al principio.

Se corrige **contra este enunciado**, no contra el template. Un grupo que se aparte de la estructura del template pero responda todo lo que este documento pide no se penaliza por apartarse.

Está permitido el uso de herramientas de IA para asistir la escritura, el análisis y la programación, con una sola condición: **la comprensión es propia e intransferible**. Se podrá pedir a cualquier integrante que explique oralmente cualquier fragmento de código, resultado o análisis entregado.